Instituto Politécnico General San Martín

Lógica y Teoría de Grafos

Trabajo Práctico Integrador

Planificación de Mesas de Examen mediante Aprendizaje Automático, Teoría de Grafos y Aplicación Web

Antonio Gómez **Luca Mamani**

Noviembre 2026

Resumen

Este trabajo práctico aborda el problema de asignación de turnos para exámenes universitarios (*University Examination Timetabling Problem*) combinando modelos de aprendizaje automático diádico, modelado formal con teoría de grafos, heurísticas de coloreo de vértices y una aplicación web interactiva de soporte a la toma de decisiones. A partir del benchmark histórico de la *University of Nottingham* (Semestre 1, 1994–95), se formula la predicción de incompatibilidades curriculares como una tarea de clasificación binaria sobre los $\binom{800}{2} = 319.600$ pares no dirigidos de materias. Para evitar la fuga de información inherente a las estructuras diádicas, se implementa una partición estratificada por materias (*Node-Holdout Split*). Se comparan múltiples algoritmos supervisados y regímenes de balanceo, seleccionando como modelo oficial un Árbol de Decisión sin ponderar (`DecisionTree_Full_Unweighted`) con corte optimizado en validación interna ($\tau = 0,20$). A partir de las probabilidades fuera de muestra (*Out-of-Fold*), se construye un grafo no dirigido de conflictos ($|V| = 800, |E| = 2.032$) sobre el cual se aplican siete algoritmos constructivos de coloreo de vértices. La heurística de referencia (*Largest First* / Welsh-Powell) resuelve el cronograma en exactamente 11 turnos, satisfaciendo holgadamente la cota máxima de 32 turnos del calendario académico. Al auditar la solución frente a las inscripciones efectivas de la cohorte 1994, el sistema separa el 81,42 % de los pares en conflicto y reduce un 87,02 % las incidencias globales estudiante-par respecto del peor caso teórico, aunque retiene superposiciones en el 63,03 % de los estudiantes únicos debido a los falsos negativos derivados de la escasez informativa en materias iniciales. La arquitectura completa se integra en un monorepo modular con backend en FastAPI y frontend en React 18, TypeScript y Canvas HTML5.

Índice

1. Introducción y Descripción del Problema **2**
- 1.1. Contexto y Definición del Problema . . . 2
- 1.2. Modelado Formal mediante Teoría de Grafos . . . 3
- 1.3. Decisiones de Diseño y Formulación Metodológica . . . 3

2. Datos Utilizados y Preprocesamiento **4**
- 2.1. Comparación y Selección del Conjunto de Datos . . . 4
- 2.2. Estrategia de Cohortes y Construcción de Díadas . . . 4
- 2.3. Variables Predictoras y Prevención de Fuga de Información . . . 5

3. Metodología de Aprendizaje Automático **5**
3.1. Partición por Materias (*Node-Holdout Split*) 5
3.2. Tratamiento del Desbalance de Clases 6
3.3. Modelos Evaluados y Optimización de Umbrales 6
3.4. Selección del Modelo Oficial 6

4. Construcción del Grafo y Generación del Cronograma **7**
4.1. Construcción del Grafo y Propiedades Topológicas de $G(\tau)$ 7
4.2. Cotas Teóricas del Número Cromático $\chi(G)$ 7
4.3. Análisis Comparativo de Heurísticas de Coloreo 8
4.4. Barrido de Umbrales (τ) y Análisis de No-Monotonicidad 9

5. Desarrollo e Integración del Sistema **9**
5.1. Flujo de Integración entre Aprendizaje Automático y Teoría de Grafos 9
5.2. Arquitectura General del Prototipo 9
5.3. Diseño e Implementación de la Interfaz Web (Frontend) 10
5.3.1. Capa de Transporte Desacoplada y Modo Offline (`apiClient.ts`) 10
5.4. Esquema y Distribución Visual de la Interfaz Web 11

6. Resultados y Evaluación **11**
6.1. Evaluación del Cronograma contra la Verdad de Campo de 1994 11
6.2. Distinción entre Pares de Materias, Incidencias y Alumnos Únicos 11

7. Limitaciones y Posibles Mejoras **12**
7.1. Limitaciones del Conjunto de Datos y de la Estrategia Temporal 12
7.2. Dificultades Estructurales del Problema Diádico 12
7.3. Posibles Mejoras Futuras 13

8. Uso de Herramientas de Inteligencia Artificial **13**
8.1. Herramientas Empleadas y Entornos de Trabajo 13
8.2. Tareas Concretas en las que Colaboraron las Herramientas 13
8.3. Análisis Crítico, Alucinaciones y Desafíos Técnicos Enfrentados 14
8.4. El Rol Indispensable de la Supervisión Humana 15

9. Conclusiones **15**

---

1. Introducción y Descripción del Problema

1.1. Contexto y Definición del Problema

La secretaría académica de una facultad debe confeccionar el cronograma de exámenes finales de cada período lectivo. La planificación enfrenta dos requerimientos operativamente contrapuestos:

a) **Disponibilidad estudiantil (Restricción de No Superposición):** Evitar que dos asignaturas con estudiantes en común se programen en el mismo día y turno horario, ya que la colisión horaria (*clash*) imposibilita al alumno rendir ambas materias.

b) **Límite de capacidad temporal del calendario:** El calendario académico dispone de una cota máxima estricta de turnos disponibles ($T_{\text{máx}} = 32$ turnos, distribuidos a lo largo de dos semanas hábiles), por lo que resulta físicamente inviable asignar una franja horaria exclusiva a cada una de las 800 materias.

En la práctica universitaria, las fechas de examen deben fijarse y publicarse obligatoriamente antes de que los estudiantes formalicen su inscripción a las mesas. En consecuencia, la matriz de incompatibilidades no se conoce con certeza de antemano. El objetivo central de este proyecto es estimar qué pares de materias presentarán conflicto en una nueva cohorte utilizando aprendizaje automático sobre atributos curriculares e históricos, construir un grafo formal de restricciones a partir de dichas predicciones, y resolver la asignación de turnos mediante algoritmos de coloreo de grafos.

1.2. Modelado Formal mediante Teoría de Grafos

El problema de asignación de turnos de examen se modela canónicamente como un problema de **coloreo propio de vértices en un grafo no dirigido**:

- El catálogo de asignaturas se modela como un conjunto finito de vértices $V = \{v_1, v_2, \ldots, v_n\}$, donde $|V| = 800$.
- Cada incompatibilidad estimada entre dos asignaturas distintas se modela como una arista no dirigida $\{u, v\} \in E$, indicando que ambas materias no pueden dictarse simultáneamente.
- El conjunto de turnos horarios disponibles se modela como un conjunto discreto de colores enteros $C = \{1, 2, \ldots, k\} \subset \mathbb{N}$, sujeto a la restricción de capacidad $k \leq 32$.

Una asignación admisible de turnos equivale a una función de coloreo de vértices $c : V \to \{1, \ldots, k\}$ que satisface la propiedad de **coloreo propio**:

$$\forall \{u, v\} \in E \implies c(u) \neq c(v) \tag{1}$$

El valor mínimo k para el cual existe un coloreo propio se denomina **número cromático** del grafo, denotado por $\chi(G)$. Dado que determinar $\chi(G)$ es un problema clásico $\mathcal{NP}$-difícil (Karp, 1972) y su decisión es $\mathcal{NP}$-completa para $k \geq 3$, resulta computacionalmente intratable calcular la solución exacta sobre grafos densos de gran escala. Por ello, se apela a algoritmos constructivos voraces (*greedy*) que garantizan coloreos válidos en tiempo polinomial $\mathcal{O}(|V| + |E|)$.

1.3. Decisiones de Diseño y Formulación Metodológica

1. **Clasificación binaria frente a regresión:** Se optó por formular la tarea de aprendizaje automático como clasificación binaria probabilística ($y = 1$ si hay conflicto, $y = 0$ si no lo hay). En la confección de cronogramas, la presencia de estudiantes compartidos constituye una restricción lógica que prohíbe el solapamiento, independientemente de la cantidad exacta de alumnos. Asimismo, en una regresión sobre el número de alumnos afectados, la gran proporción de pares sin conflicto (98,6 %) sesga negativamente las estimaciones lineales hacia cero.

2. **Desacoplamiento entre predicción y coloreo:** El modelo predictivo estima probabilidades continuas $\hat{p}_{uv} \in [0, 1]$. A partir de un umbral de decisión $\tau \in (0, 1)$, se define el conjunto de aristas del grafo predicho:

$$E(\tau) = \{\{u, v\} \subset V \mid u \neq v \wedge \hat{p}_{uv} \geq \tau\} \tag{2}$$

   El algoritmo de coloreo opera sobre el grafo no ponderado $G(\tau) = (V, E(\tau))$, asegurando determinísticamente que ninguna arista predicha sea violada en el cronograma resultante.

3. **Compromiso operativo entre turnos y choques (Tradeoff Precisión vs. Recall):** En este esquema, los dos tipos de error de clasificación tienen implicancias operativas disimétricas:

- *Falsos Negativos (FN):* Conflictos reales no detectados por el modelo. Pueden provocar que dos materias incompatibles reciban el mismo turno, generando choques horarios efectivos para los alumnos.
- *Falsos Positivos (FP):* Conflictos predichos donde en la realidad no hay estudiantes compartidos. Agregan aristas ficticias que aumentan el grado de los nodos y pueden forzar al algoritmo a requerir una mayor cantidad de turnos, arriesgando la superación del límite del calendario ($T > 32$).

El umbral τ actúa como un parámetro de calibración de riesgo: reducir τ aumenta el recall (protegiendo a más alumnos a costa de densificar el grafo y requerir potencialmente más turnos), mientras que elevar τ relaja las restricciones y compacta el cronograma, a expensas de tolerar más superposiciones reales.

2. Datos Utilizados y Preprocesamiento

2.1. Comparación y Selección del Conjunto de Datos

Se evaluaron tres conjuntos de datos públicos de uso extendido en la literatura de planificación de exámenes:

1. **Toronto Benchmark Dataset (Carter et al., 1996):** Colección de 13 instancias de 12 instituciones. Los archivos contienen identificadores numéricos y listas de inscripción por alumno, pero no incluyen metadatos curriculares interpretables (nombres de materias, carreras, departamentos, niveles de cursada ni definiciones de calendario académico).

2. **Purdue University UniTime Dataset (MISTA 2013):** 9 archivos XML de gran tamaño (153 MB). Al igual que en Toronto, los exámenes están renumerados arbitrariamente en cada semestre sin metadatos curriculares que permitan vincular materias entre períodos.

3. **University of Nottingham Dataset (1994–95):** Padrón correspondiente al Semestre 1 del año 1994–95. Contiene los nombres de las 800 materias, sus códigos curriculares modulares, la duración de cada examen, 46 departamentos académicos, 223 códigos de carrera (`course code`) y el padrón de 7.896 alumnos con su año de ingreso. Asimismo, especifica el calendario de 32 turnos disponibles.

La Tabla 1 resume la comparación entre los tres conjuntos. Se seleccionó el dataset de Nottingham debido a que es el único que conserva atributos académicos interpretables para construir las variables requeridas por la consigna (`mismo_anio`, `misma_carrera`).

2.2. Estrategia de Cohortes y Construcción de Díadas

A partir del catálogo de 800 materias se construyeron los $\binom{800}{2} = 319.600$ pares no dirigidos posibles. Para aproximar el escenario donde se planifica un período lectivo futuro basándose en información previa, se aprovechó el código de ingreso de los alumnos:

- **Cohortes históricas (1989–1993):** 4.810 estudiantes (19.798 inscripciones). Con estos datos se construyeron exclusivamente las variables predictoras basadas en co-inscripción y planes de estudio compartidos.
- **Cohorte objetivo (1994):** 3.086 estudiantes (14.199 inscripciones). Con estos datos se generaron únicamente las etiquetas de evaluación ($y = 1$ si compartieron al menos un alumno en 1994, $y = 0$ en caso contrario, y el recuento de alumnos afectados).

Criterio	Univ. of Nottingham	Toronto Benchmark	Purdue UniTime
Archivos y formato	4 archivos ASCII + README (<1 MB).	26 archivos planos (.crs / .stu).	9 archivos XML (153 MB).
Nombres de materia	Sí, nombres reales completos.	No (identificadores numéricos).	No (identificadores numéricos).
Carrera del alumno	Sí (223 planes en `students`).	No disponible.	No disponible.
Nivel / Año de materia	Sí, codificado en el identificador.	No disponible.	No disponible.
Turnos de calendario	Sí (32 turnos en `data`).	No incluidos en los archivos.	Sí (29 períodos por XML).
Vínculo temporal	Cohortes de ingreso (1989 a 1994).	Renumeración independiente.	Renumeración independiente.
Aptitud para el TP	Permite derivar variables curriculares.	Requiere inventar atributos.	Requiere inventar atributos.

Cuadro 1: Comparación técnica de los conjuntos de datos analizados.

2.3. Variables Predictoras y Prevención de Fuga de Información

Para evitar fuga de información (*data leakage*) hacia el modelo predictivo, se excluyeron de la matriz de entrada:

- Las matrículas de 1994 (`cant_inscriptos_actual_1/2`) y la tasa de afectados, ya que provienen de la cohorte objetivo.
- La variable `tasa_compartidos_historico`, por presentar colinealidad exacta ($r = 1,0$) con `cant_estudiantes_compartidos_historico`.
- Los identificadores de materia, que se conservan solo como metadatos para armar el grafo.

La Tabla 2 describe las 10 variables predictoras seleccionadas para el modelo.

3. Metodología de Aprendizaje Automático

3.1. Partición por Materias (*Node-Holdout Split*)

En problemas diádicos, una división aleatoria convencional de pares generaría que las 800 materias aparezcan simultáneamente en entrenamiento y prueba (cada materia participa en 799 filas). Esto permitiría a modelos no lineales memorizar los atributos marginales de una materia específica (`cant_inscriptos_hist_1/2`) y transferir esa información entre pares de entrenamiento y prueba.

Para mitigar esta fuga, se aplicó una partición estratificada por materias (*Node-Holdout Split*):

1. Se reservaron 86 materias para prueba (`test_subjects`, 10,75 %) y 714 para entrenamiento (`train_subjects`, 89,25 %), estratificando por nivel curricular con semilla fija (`RANDOM_SEED = 42`).
2. **Conjunto de Entrenamiento (`ml_train_full.csv`):** Pares donde ambas materias pertenecen a `train_subjects` ($\binom{714}{2} = 254.541$ pares, 79,64 % del total).
3. **Conjunto de Prueba (`ml_test_full.csv`):** Pares donde al menos una materia pertenece a `test_subjects` (65.059 pares, 20,36 % del total).

#	Variable	Tipo	Descripción
1	`mismo_departamento`	Binaria	1 si ambas materias pertenecen al mismo departamento académico (46 departamentos).
2	`mismo_prefijo_curricular`	Binaria	1 si coinciden los dos primeros caracteres del código de materia (`exam_id[:2]`).
3	`anio_confirmado`	Binaria	1 si ambas materias tienen año numérico explícito en su código (`1..4`).
4	`mismo_anio`	Binaria	1 si `anio_confirmado == 1` y ambas coinciden en año de cursada.
5	`misma_carrera`	Binaria	1 si compartieron al menos una carrera (`course_code`) en las cohortes 1989–1993.
6	`cant_carreras_compartidas_hist`	Entero	Cantidad de carreras donde coexisten ambas asignaturas históricamente.
7	`cant_inscriptos_hist_1`	Entero	Total de alumnos inscriptos en la primera materia (cohortes 1989–1993).
8	`cant_inscriptos_hist_2`	Entero	Total de alumnos inscriptos en la segunda materia (cohortes 1989–1993).
9	`cant_estudiantes_compartidos_hist`	Entero	Alumnos de 1989–1993 que rindieron ambas materias.
10	`jaccard_historico`	Continuo	Coeficiente de similitud de Jaccard sobre alumnos históricos: $\frac{\lvert E_1 \cap E_2 \rvert}{\lvert E_1 \cup E_2 \rvert}$.

Cuadro 2: Variables predictoras utilizadas en el entrenamiento.

Para ajustar hiperparámetros y optimizar los umbrales de decisión sin consultar el conjunto de prueba, se aplicó la misma partición por materias internamente sobre el conjunto de entrenamiento: 637 materias para sub-entrenamiento (202.566 pares) y 77 materias para validación interna (51.975 pares, con 662 pares positivos y prevalencia natural del 1,27 %).

3.2. Tratamiento del Desbalance de Clases

La variable objetivo presenta un desbalance severo: en el conjunto completo de 319.600 pares, solo 4.468 son positivos (1,40 % de prevalencia). Se evaluaron tres regímenes de entrenamiento: `Balanced` (submuestreo 50/50), `Full_Unweighted` (distribución natural completa) y `Full_ClassWeight` (ponderación analítica de la pérdida). El régimen no ponderado conservó la distribución empírica de probabilidades, resultando indispensable para calibrar el umbral operativo τ.

3.3. Modelos Evaluados y Optimización de Umbrales

Se entrenaron modelos de Árbol de Decisión (`max_depth=5`), Regresión Logística regularizada y KNN ($K = 15$). Para cada modelo se determinó en validación interna el umbral óptimo τ^*_{val} que maximizara el puntaje F_1. La Tabla 3 expone la evaluación final sobre el conjunto de prueba independiente.

3.4. Selección del Modelo Oficial

La elección de `DecisionTree_Full_Unweighted` ($\tau = 0,20$) se fundamentó en su desempeño en validación ($F_1 = 0,2615$, PR-AUC $= 0,1963$) y en su alta precisión sobre aristas inéditas en test (43,99 % frente a 27,11 % de KNN), cometiendo solo 191 falsos positivos frente a los 648 de KNN. Para la etapa de grafos, evitar falsos positivos es crítico para no densificar el grafo con enlaces espurios que colapsen el calendario de turnos.

Modelo y Régimen	Umbral τ	Precision	Recall	F_1-Score	PR-AUC	TP	FP	FN
Baseline Mayoritario	0,50	0,0000	0,0000	0,0000	0,0149	0	0	970
Baseline Heurístico Histórico	—	0,1428	0,2082	0,1694	0,0750	202	1.213	768
`DecisionTree_Balanced`	0,50	0,0456	0,8526	0,0866	0,1439	827	17.303	143
`DecisionTree_Balanced_UmbralVal`	0,90	0,1431	0,3680	0,2061	0,1439	357	2.138	613
`DecisionTree_Full_Unweighted`	0,50	0,9531	0,0629	0,1180	0,2082	61	3	909
`DecisionTree_Full_Unweighted_UmbralVal` (Oficial)	**0,20**	**0,4399**	**0,1546**	**0,2288**	**0,2082**	**150**	**191**	**820**
`LogisticRegression_Balanced`	0,50	0,0636	0,7588	0,1173	0,1384	736	10.843	234
`LogisticRegression_Balanced_UmbralVal`	0,94	0,2442	0,2485	0,2463	0,1384	241	746	729
`LogisticRegression_Full_ClassWeight`	0,94	0,2646	0,2381	0,2507	0,1519	231	642	739
`KNN_Balanced`	0,50	0,0623	0,8134	0,1157	0,1183	789	11.876	181
`KNN_Full_Unweighted`	0,50	0,5597	0,0918	0,1577	0,1833	89	70	881
`KNN_Full_Unweighted_UmbralVal`	0,21	0,2711	0,2485	0,2593	0,1833	241	648	729

Cuadro 3: Métricas sobre el conjunto de prueba independiente (`ml_test_full.csv`, 65.059 pares, 970 positivos).

4. Construcción del Grafo y Generación del Cronograma

4.1. Construcción del Grafo y Propiedades Topológicas de $G(\tau)$

Para construir el grafo del catálogo completo (319.600 pares) sin incurrir en sesgo optimista *in-sample*, se utilizó una matriz de probabilidades fuera de muestra (*Out-of-Fold*, OOF) precalculada (`pair_probabilities_oof.csv`) mediante validación cruzada en 5 pliegues agrupada por materias.

Con el umbral oficial $\tau = 0,20$, el grafo de conflictos predicho $G(0,20) = (V, E(0,20))$ exhibe las siguientes propiedades topológicas calculadas formalmente:

- **Orden del grafo ($|V|$):** 800 vértices (la totalidad de los exámenes).
- **Tamaño del grafo ($|E|$):** 2.032 aristas predichas como conflictivas ($\hat{p}_{uv} \geq 0,20$).
- **Densidad de aristas (ρ):** $\rho(G) = \frac{2|E|}{|V|(|V|-1)} = \frac{4.064}{639.200} \approx 0,006358$ $(0,64\,\%)$.
- **Grado medio de los vértices ($\bar{d}$):** $\bar{d} = \frac{2|E|}{|V|} = \frac{4.064}{800} = 5,08$ conflictos promedio por materia.
- **Grado máximo ($\Delta(G)$):** $\Delta(G) = 38$ aristas concurrentes sobre la asignatura más conflictiva del plan común de ingeniería.
- **Vértices aislados (V_{iso}):** 110 materias satisfacen $\deg(v) = 0$. Corresponden a asignaturas terminales o de posgrado modular que no presentan riesgo predicho con ninguna otra materia del catálogo. Estas materias pueden ser programadas libremente en cualquier turno sin generar choques.
- **Componentes conexas (k_{cc}):** 133 componentes conexas independientes. La componente gigante concentra 658 asignaturas fuertemente entrelazadas por planes de estudio compartidos, mientras que las restantes corresponden a subgrafos pequeños o nodos aislados.

4.2. Cotas Teóricas del Número Cromático $\chi(G)$

El número cromático $\chi(G)$ de un grafo se encuentra acotado teóricamente por magnitudes topológicas fundamentales:

1. **Cota inferior por Número de Clique ($\omega(G)$):** Si un grafo contiene un subgrafo completo K_m de tamaño m, se requiere un color distinto para cada uno de sus vértices:

$$\chi(G) \geq \omega(G) \tag{3}$$

En $G(0, 20)$, el clique maximal identificado contiene $\omega(G) = 8$ materias, lo que establece que ningún algoritmo puede resolver el cronograma en menos de 8 turnos.

2. **Cota superior de Brooks (1941):** Para todo grafo conexo que no sea un grafo completo K_n ni un ciclo impar C_{2k+1}, el número cromático está acotado por el grado máximo:

$$\chi(G) \leq \Delta(G) = 38 \tag{4}$$

Dado que $38 > 32$, la cota superior general de Brooks no bastaba por sí sola para asegurar que el cronograma entrara en el calendario escolar de 32 turnos.

3. **Cota de Welsh-Powell (1967):** Ordenando los vértices de manera que $d(v_1) \geq d(v_2) \geq \cdots \geq d(v_n)$, el algoritmo voraz garantiza:

$$\chi(G) \leq \max_i \min\{d(v_i) + 1,\ i\} \tag{5}$$

En $G(0, 20)$, esta cota constructiva desciende a 14 turnos, demostrando teóricamente la viabilidad del calendario antes de ejecutar el coloreo.

4.3. Análisis Comparativo de Heurísticas de Coloreo

El backend de la aplicación implementa siete estrategias voraces de coloreo provistas por `NetworkX`, evaluadas exhaustivamente sobre $G(0, 20)$:

1. ***Largest First* (Welsh-Powell):** Ordena los vértices en orden descendente de grado global estático ($\deg(v)$). Colorea primero los nodos con mayores restricciones, relegando los vértices de bajo grado al final. Resuelve el cronograma oficial en exactamente **11 turnos**.

2. ***Saturation Largest First* (DSATUR, Brélaz 1979):** Heurística dinámica que evalúa en cada paso el *grado de saturación* $s(v)$ (cantidad de colores diferentes ya utilizados por sus vecinos adyacentes). Selecciona en cada iteración el vértice con mayor saturación, desempatando por grado no coloreado. Obtiene también **11 turnos**, produciendo una distribución de turnos más balanceada en carga de estudiantes.

3. ***Smallest Last* (Matula y Beck, 1983):** Calcula un orden de eliminación removiendo iterativamente el vértice de grado mínimo en el subgrafo residual, invirtiendo luego el orden para colorear. Garantiza no superar la cota del subgrafo degenerado y colorea en **11 turnos**.

4. ***Independent Set*:** Extrae de forma iterativa conjuntos independientes maximales voraces, asignando un mismo color a todos los vértices del conjunto antes de avanzar al siguiente. Requiere **12 turnos**.

5. ***Random Sequential*:** Colorea los vértices en una permutación aleatoria uniforme. Al carecer de criterio de ordenamiento, suele fragmentar las opciones cromáticas, requiriendo entre **13 y 15 turnos** según la semilla aleatoria.

6. ***Connected Sequential BFS / DFS*:** Recorren las componentes conexas en anchura o profundidad, asignando colores conforme se descubren los nodos. Producen soluciones de entre **12 y 14 turnos**.

Todas las heurísticas generan coloreos formalmente válidos sobre $G(\tau)$, garantizando que ningún par predicho como conflictivo comparta turno. Se ratifica ***Largest First*** como la estrategia oficial de referencia por su rapidez, determinismo y mínima cantidad de turnos requeridos (11 turnos).

4.4. Barrido de Umbrales (τ) y Análisis de No-Monotonicidad

Para comprender la dinámica de la planificación ante variaciones en el corte probabilístico, se ejecutó un barrido paramétrico sobre $\tau \in [0,05; 0,50]$. La Tabla 4 resume el comportamiento estructural del grafo y del cronograma resultante.

Umbral τ	Aristas $\lvert E \rvert$	Turnos	Cabe (≤ 32)	Pares Choque	Alumnos Choque	% Choque	Precision	Recall
0,05	23.286	139	No	74	307	1,07 %	0,1063	0,5542
0,10	3.749	15	Sí	483	2.412	8,41 %	0,2769	0,2323
0,15	3.019	14	Sí	602	2.996	10,45 %	0,3087	0,2086
0,20 (Oficial)	**2.032**	**11**	**Sí**	**830**	**3.723**	**12,98 %**	**0,3735**	**0,1699**
0,25	1.659	12	Sí	940	4.371	15,24 %	0,4123	0,1531
0,30	1.029	9	Sí	1.192	5.466	19,06 %	0,5053	0,1164
0,40	669	9	Sí	1.493	6.598	23,01 %	0,6069	0,0909
0,50	524	9	Sí	1.674	7.649	26,67 %	0,6775	0,0795

Cuadro 4: Barrido de umbrales sobre el grafo OOF y evaluación frente a la cohorte 1994 (*Largest First*).

Un hallazgo teórico de singular relevancia se observa al comparar $\tau = 0,20$ (11 turnos) con $\tau = 0,25$ (12 turnos): **la cantidad de turnos requerida no es una función monótona decreciente respecto de** τ. Aunque $\tau = 0,25$ elimina 373 aristas respecto a $\tau = 0,20$ (facilitando en teoría el empaquetamiento), la eliminación de aristas altera el ordenamiento por grados de los vértices en Welsh-Powell. Esta reordenación provoca que ciertos vértices altamente conflictivos se coloreen más tarde en la secuencia, bloqueando colores previamente disponibles y forzando la apertura de un duodécimo turno. Esto demuestra formalmente que las heurísticas voraces son sensibles a perturbaciones en el ordenamiento topológico.

5. Desarrollo e Integración del Sistema

5.1. Flujo de Integración entre Aprendizaje Automático y Teoría de Grafos

El sistema articula la inferencia estadística con la optimización discreta mediante una tubería de cinco etapas continuas:

1. **Inferencia diádica continua:** El modelo oficial predice $\hat{p}_{uv} \in [0, 1]$ para los 319.600 pares.
2. **Filtrado por umbral de decisión (τ):** Se seleccionan los pares con $\hat{p}_{uv} \geq \tau$ (calibrado en $\tau = 0,20$).
3. **Construcción del grafo no dirigido:** Se instancia $G(\tau)$ en memoria con `NetworkX`.
4. **Coloreo voraz de vértices:** Se aplica Welsh-Powell para obtener la asignación de turnos sin conflictos en $G(\tau)$.
5. **Auditoría de impacto real:** Se contrastan los turnos asignados contra las inscripciones efectivas de 1994, cuantificando incidencias mitigadas y residuales.

5.2. Arquitectura General del Prototipo

El prototipo se organizó como un monorepo modular estructurado en dos subsistemas principales:

- **Backend Computacional (FastAPI v1):** Servicio REST en Python 3.10+ estructurado en capas (rutas en `src/api/v1/endpoints/`, servicios en `src/services/` y esquemas en `src/schemas/`). Durante el arranque (*lifespan*), precarga en memoria la matriz de probabilidades OOF, el catálogo de 800 materias y el registro de alumnos 1994, garantizando tiempos de respuesta sub-segundo (< 150 ms). Incluye middleware de CORS para habilitar la comunicación segura con el cliente web.

- **Frontend SPA Interactivo (React 18 + TypeScript + Vite):** Aplicación web de página única orientada al usuario y al tomador de decisiones académicas, estructurada según el principio de diseño desacoplado (*Contract-First*).

5.3. Diseño e Implementación de la Interfaz Web (Frontend)

La interfaz de usuario fue diseñada para transformar un problema analítico abstracto en una herramienta de exploración visual interactiva. El frontend se compone de cuatro módulos funcionales principales:

1. **Visualizador del Grafo de Conflictos (`GraphView.tsx`):** Dado que renderizar 800 nodos y más de 2.000 aristas mediante elementos convencionales del DOM (SVG o HTML) degrada severamente la tasa de cuadros por segundo, este componente se implementó directamente sobre la API de **Canvas HTML5**. Ofrece renderizado continuo a 60 FPS, soporte para arrastre interactivo de nodos (*drag-and-drop*), zoom dinámico con rueda de mouse y paneo bidimensional. Cada materia se colorea automáticamente de acuerdo con el turno de examen asignado por el algoritmo. Asimismo, implementa un filtro de vecindad (*ego-network*): al hacer clic sobre una materia específica, el lienzo atenúa el resto del grafo y resalta exclusivamente sus aristas de conflicto y sus vecinos directos.

2. **Explorador del Cronograma de Exámenes (`ScheduleView.tsx`):** Despliega la distribución de los 800 exámenes agrupados en columnas cronológicas por turno (del turno 0 al turno 10). Cada tarjeta de examen detalla el código de la materia, su nombre completo, el departamento académico responsable y la duración estipulada. Incluye un buscador textual en tiempo real por código o palabra clave y un selector para filtrar el cronograma por departamento académico (e.g., Medicina, Ciencias Químicas, Ingeniería).

3. **Panel de Indicadores y Métricas Ejecutivas (`MetricCards.tsx`):** Presenta un tablero de cuatro tarjetas métricas que se actualizan dinámicamente ante cualquier cambio de configuración:

   - *Turnos Utilizados:* Indica los 11 turnos requeridos frente al tope máximo de 32, con una insignia verde de validación reglamentaria (*Cabe en el calendario*).
   - *Estudiantes Protegidos:* Porcentaje de incidencias de solapamiento prevenidas (87,02 % en el umbral oficial).
   - *Precisión de Aristas:* Porcentaje de aristas predichas que corresponden a conflictos reales de la cohorte (37,35 %).
   - *Referencia Oráculo:* Indicador de referencia histórica con el ground truth (19 turnos ideales, 0 choques).

4. **Control Dinámico de Umbral y Heurísticas (`ThresholdSlider.tsx`):** Permite al usuario interactuar en tiempo real con el compromiso entre turnos y choques. Incorpora un deslizador para ajustar el umbral $\tau \in [0,01; 0,99]$ equipado con un temporizador de *debouncing* (250 ms) para evitar sobrecargar el backend con peticiones intermedias mientras se arrastra el control. Asimismo, incluye un selector desplegable para alternar en vivo entre las 7 heurísticas de coloreo implementadas (*Largest First*, DSATUR, *Smallest Last*, etc.), permitiendo al usuario comparar inmediatamente cómo cambia la cantidad de turnos requerida.

5.3.1. Capa de Transporte Desacoplada y Modo Offline (`apiClient.ts`)

Para asegurar la robustez de la aplicación y permitir su demostración sin necesidad de tener el servidor backend levantado, el cliente web implementa un patrón de transporte dual:

- **Modo Online (Conectado a la API REST):** Cuando la variable de entorno `VITE_API_URL` está definida (e.g., `http://localhost:8000`), el cliente realiza consultas HTTP asíncronas a los endpoints oficiales de FastAPI (`/api/v1/schedule`, `/api/v1/schedule/evaluate`, `/api/v1/schedule/sweep` y `/api/v1/graph`).
- **Modo Offline (Simulación con Mocks Reales):** Si no se detecta conexión o no se especifica URL del backend, el cliente recurre de forma transparente a los artefactos precalculados almacenados en `src/mock/`, permitiendo explorar el grafo completo de 2.032 aristas y el cronograma oficial de 11 turnos de manera totalmente autónoma.

5.4. Esquema y Distribución Visual de la Interfaz Web

La Figura 1 ilustra la distribución funcional de los paneles en la aplicación web integrada.

Encabezado de Navegación y Estado del Servidor	
Selector de Umbral Dinámico ($\tau = 0, 20$) | Selector de Heurística (*Largest First*)	
Panel de Métricas y KPIs	**Visualizador de Grafo en Canvas HTML5**
• 11 / 32 Turnos (Válido)	• 800 vértices coloreados por turno
• 87,02 % Alumnos Protegidos	• 2.032 aristas de incompatibilidad
• 37,35 % Precisión de Aristas	• Zoom, arrastre y filtro de vecinos directos
Distribución de Exámenes por Turno (Schedule Grid)	
Filtro por Departamento | Buscador de Examen en tiempo real	
Columnas de Turnos: [Turno 0 (78 materias)] ... [Turno 10 (64 materias)]	

Figura 1: Diagrama de bloques y arquitectura visual de la interfaz de usuario desarrollada.

6. Resultados y Evaluación

6.1. Evaluación del Cronograma contra la Verdad de Campo de 1994

Para medir el impacto del cronograma en un escenario real, se cruzó la asignación de turnos oficial ($\tau = 0, 20$, *Largest First*) contra las inscripciones efectivas de los 3.086 alumnos de la cohorte 1994. En dicha cohorte existieron **4.468 pares de materias con alumnos compartidos**. La Tabla 5 presenta los resultados oficiales obtenidos.

6.2. Distinción entre Pares de Materias, Incidencias y Alumnos Únicos

Para interpretar correctamente la evaluación, es imprescindible diferenciar tres unidades de análisis con semánticas matemáticas distintas:

1. **Pares de materias en conflicto (`pares_reales` y `clashing_pairs`):** Corresponde a las aristas del grafo oráculo. En la cohorte 1994 existen **4.468 pares de materias** con conflicto. El cronograma oficial separa a **3.638 pares (81,42 % de reducción)**, mientras que **830 pares (18,58 %)** coinciden en un mismo turno por no haber sido detectados por el modelo de ML (falsos negativos).

2. **Incidencias estudiante-par (`total_affected_students` y `clashing_students`):** Cuantifica la sumatoria de solapamientos individuales: $\sum_s \binom{k_s}{2}$. En el escenario teórico de turno único ($T = 1$), se generarían **28.677 incidencias potenciales**. En el cronograma oficial de 11 turnos, únicamente **3.723 incidencias** coinciden en horario, logrando una **reducción del 87,02 %** (24.954 incidencias prevenidas).

Métrica	Cronograma Oficial	Grafo Oráculo (Ground Truth)	Interpretación
Turnos utilizados	**11 turnos**	19 turnos	Cumple holgadamente el límite de 32 turnos del calendario.
Cabe en calendario	**Sí**	Sí	Restricción temporal satisfecha.
A nivel de pares de materias (aristas del grafo):			
Aristas predichas ($\|E\|$)	2.032 aristas	4.468 aristas	Restricciones incorporadas al grafo ($G(0, 20)$ vs. oráculo).
Pares reales en conflicto	4.468 pares	4.468 pares	Pares de materias con co-inscripciones en 1994.
Pares reales evitados	**3.638 pares (81,42 %)**	4.468 pares (100 %)	Asignados a turnos diferentes (choque evitado).
Pares reales en choque	**830 pares (18,58 %)**	0 pares (0,00 %)	Falsos negativos asignados al mismo turno.
A nivel de incidencias estudiante-par (volumen de conflicto):			
Incidencias potenciales ($T = 1$)	28.677	28.677	Cota teórica en el peor caso de asignación en un único turno.
Incidencias mitigadas	**24.954 (87,02 %)**	28.677 (100 %)	Superposiciones diádicas prevenidas por el cronograma.
Incidencias residuales en choque	**3.723 (12,98 %)**	0 (0,00 %)	Violaciones efectivas de horario en el cronograma oficial.
A nivel de estudiantes únicos (personas físicas / headcount):			
Alumnos únicos evaluados	3.086 alumnos	3.086 alumnos	Población total de la cohorte 1994.
Alumnos únicos con ≥ 1 choque	**1.945 alumnos**	0 alumnos	Personas físicas con al menos un solapamiento horario.
Porcentaje de alumnos afectados	**63,03 %**	0,00 %	Proporción de la población estudiantil que sufre choques.

Cuadro 5: Evaluación del cronograma oficial ($\tau = 0, 20$, *Largest First*) frente a las inscripciones reales de 1994.

3. **Alumnos únicos afectados (`unique_students_affected`):** Mide personas físicas reales (*headcount*), donde cada estudiante se computa a lo sumo una vez si experimenta al menos una colisión horaria. En la cohorte 1994, **1.945 de los 3.086 alumnos (63,03 %)** sufren al menos un choque horario.

Esta distinción aclara por qué una reducción del 87,02 % en volumen de conflicto convive con un 63,03 % de alumnos afectados. En la cohorte 1994 los estudiantes registran una media de 4,6 inscripciones a examen ($\frac{14.199 \text{ inscripciones}}{3.086 \text{ alumnos}}$), lo que sitúa a cada alumno en múltiples pares potenciales de conflicto ($\binom{4,6}{2} \approx 10,6$ pares por alumno). Dado que basta con que una sola de sus materias coincida en turno con otra para computar al estudiante como afectado, los 830 pares en conflicto no prevenidos terminan alcanzando al 63,03 % de la población estudiantil.

7. Limitaciones y Posibles Mejoras

7.1. Limitaciones del Conjunto de Datos y de la Estrategia Temporal

El conjunto de datos de Nottingham corresponde a un único período académico (Semestre 1, 1994–95), por lo que no dispone de series temporales multianuales para modelar trayectorias completas. La separación temporal por año de ingreso (1989–1993 histórica vs. 1994 objetivo) introduce una limitación estructural: las cohortes históricas contienen estudiantes avanzados, mientras que la cohorte 1994 representa a los ingresantes. En consecuencia, las materias de primer año carecen de co-inscripciones históricas previas, privando al modelo de sus señales más fuertes.

7.2. Dificultades Estructurales del Problema Diádico

En el conjunto de prueba, 49.244 de los 65.059 pares (75,69 %) presentan valores nulos en las cinco señales relacionales clave: estudiantes compartidos históricos, carrera, año, departamento y prefijo curricular. A pesar de carecer totalmente de estas señales, este grupo contiene 215 conflictos reales en prueba (22,16 % de los positivos). Cuando dos materias no presentan regularidades observables en los datos disponibles, ningún clasificador supervisado puede anticipar la co-inscripción sin incurrir en una explosión masiva de falsos positivos.

7.3. Posibles Mejoras Futuras

- **Coloreo Ponderado de Grafos:** Incorporar la cantidad estimada de alumnos compartidos como peso de las aristas (w_{uv}), formulando el problema como una minimización de costo de corte (*Min-Weight Vertex Coloring*) para concentrar la penalización en pares masivos.
- **Metaheurísticas de Optimización Combinatoria:** Aplicar algoritmos de búsqueda local guiada, recocido simulado (*Simulated Annealing*) o Algoritmos Genéticos para post-procesar el cronograma voraz y reducir los 830 choques residuales aprovechando los 21 turnos libres del calendario (utilizar 25 o 28 turnos en vez de solo 11).
- **Restricciones de Recursos Físicos:** Extender el modelo incorporando la capacidad física de las aulas, distribución horaria de docentes y restricciones blandas de descanso (evitar exámenes en días consecutivos para un mismo estudiante).

8. Uso de Herramientas de Inteligencia Artificial

En cumplimiento con las consignas pedagógicas e institucionales del trabajo práctico, se declara y detalla de manera exhaustiva el uso de asistentes y herramientas de inteligencia artificial generativa durante el desarrollo del proyecto.

8.1. Herramientas Empleadas y Entornos de Trabajo

El proyecto se desarrolló bajo la modalidad de **programación en pareja asistida por IA** (*AI-assisted Pair Programming*), utilizando dos modelos de lenguaje principales:

- **Google Antigravity (Gemini 2.5 Pro y Flash):** Utilizado como asistente de desarrollo interactivo en el entorno local para exploración del código, automatización de comandos CLI, diseño de esquemas Pydantic y generación de componentes React.
- **Anthropic Claude 3.5 Sonnet / Opus:** Empleado para razonamiento algorítmico complejo, auditoría metodológica del problema diádico, depuración de pruebas matemáticas e inspección de consistencia lógica del informe en LaTeX.

8.2. Tareas Concretas en las que Colaboraron las Herramientas

La intervención de los modelos de IA se estructuró a lo largo de las distintas etapas del proyecto:

1. **Ingesta de Datos y Parsing de Archivos Históricos (Fase 1):** Los archivos originales del dataset de Nottingham presentaban un formato ASCII de ancho fijo con irregularidades en los delimitadores de columnas y encabezados no convencionales. La IA asistió en la generación del parser robusto `parse_nott.py`, implementando expresiones regulares y cortes de caracteres validados para transformar los registros en dataframes limpios de Pandas sin pérdida de registros.
2. **Construcción del Dataset Diádico y Prevención de Fuga (Fase 2):** Durante la generación de las combinaciones $\binom{800}{2} = 319.600$, la IA colaboró en la optimización vectorizada de los cruces de conjuntos para computar el índice de Jaccard histórico y la concurrencia curricular. Crucialmente, la IA participó en el análisis de *data leakage*: ante una propuesta inicial de partición aleatoria convencional de pares, se identificó que dicha estrategia permitía la memorización de identificadores. La IA asistió en la codificación de la partición estratificada por nodos (*Node-Holdout Split*), asegurando que las materias de test permanecieran estrictamente aisladas del subgrafo de entrenamiento.

3. **Implementación del Pipeline de Inferencia y Grafos (Fases 3 y 4):** Asistencia en la estandarización del módulo `src/inference/predict_conflicts.py` bajo el principio de Fuente Única de Verdad (SSOT) consumiendo `metrics_summary.json`. Asimismo, colaboró en la implementación automatizada de las 7 heurísticas voraces de `NetworkX` y en la ejecución del script de barrido paramétrico (`threshold_sweep.csv`).

4. **Desarrollo del Backend de Servicios (FastAPI v1):** Generación de código esqueleto para la arquitectura por capas del backend, definición de modelos y validadores de `Pydantic` v2, configuración de middlewares de CORS y estructuración de la función de ciclo de vida (*lifespan*) para mantener en memoria las matrices de datos y evitar cuellos de botella de entrada/salida.

5. **Desarrollo del Frontend Web (React 18 + TypeScript + Vite):** Escritura de los componentes funcionales de React, en particular la matemática trigonométrica y de transformación de coordenadas para el renderizado interactivo en Canvas HTML5 (`GraphView.tsx`), el control de eventos de arrastre de nodos, y la implementación de la capa de transporte desacoplada con soporte de modo offline (`apiClient.ts`).

6. **Suite de Pruebas Automatizadas (Testing):** Generación y mantenimiento de la suite de 47 pruebas unitarias y de integración en `unittest`, asegurando la cobertura completa de aserciones algebraicas invariantes (e.g., verificar que $\mathrm{TP} + \mathrm{FP} + \mathrm{FN} =$ pares reales y que ningún par conectado en $G(\tau)$ reciba colores idénticos).

7. **Composición Tipográfica en LaTeX:** Asistencia en la conversión de tablas complejas de resultados a sintaxis de `booktabs` y `tabularx`, corrección de desbordes de margen (*overfull hbox*) y depuración de caracteres de escape especiales.

8.3. Análisis Crítico, Alucinaciones y Desafíos Técnicos Enfrentados

El uso intensivo de herramientas generativas no estuvo exento de fricciones y requirió supervisión técnica permanente:

- **Alucinación de Firmas y Métodos Obsoletos:** En reiteradas oportunidades, los modelos sugirieron firmas deprecadas de librerías modernas (e.g., parámetros en desuso de `networkx.greedy_color` o sintaxis obsoleta de Pydantic v1 como `dict()` en lugar de `model_dump()`). Fue necesario recurrir a la documentación oficial y forzar la actualización de patrones.

- **Dificultades con el Entorno de Ejecución (Windows):** Las herramientas de IA tendían a generar scripts asumiendo entornos POSIX/Linux (comandos `grep`, manejos de señales `SIGTERM` y barras directas `/`). Al ejecutarse en Windows PowerShell, esto provocó errores de bloqueo de procesos en puertos de red (`Errno 10048` al reiniciar el servidor FastAPI) y bloqueos de archivos abiertos durante la ejecución de los tests. La resolución requirió guiar explícitamente a la IA para manipular procesos con cmdlets de PowerShell y emplear `pathlib.Path`.

- **Tendencia al Sesgo de Clasificación Simple:** En las primeras iteraciones, la IA propuso optimizar los clasificadores basándose en *Accuracy* estándar. Dado el desbalance del 98,6 %, esto derivaba en modelos triviales que predecían cero aristas. El equipo debió corregir la función objetivo hacia PR-AUC y F_1-score con optimización de umbrales en validación interna.

8.4. El Rol Indispensable de la Supervisión Humana

El aporte más crítico de los integrantes del grupo consistió en el **criterio analítico y la auditoría metodológica**. Un ejemplo paradigmático ocurrió durante la evaluación final: mientras que los modelos de lenguaje interpretaban inicialmente que la reducción del 87,02 % en incidencias diádicas representaba un éxito casi total en la planificación, la auditoría humana exigió medir el impacto en personas físicas (*headcount*). Fue la intervención humana la que formuló y ejecutó el cálculo de alumnos únicos afectados, descubriendo que el 63,03 % de los estudiantes reales retenía al menos un choque debido a la distribución concentrada de materias. Todas las decisiones de corte operativo, la selección del árbol sobre KNN y la validación matemática fueron conducidas y validadas por los autores.

9. Conclusiones

El presente trabajo práctico integrador logró articular de manera completa, rigurosa y reproducible la cadena metodológica propuesta por la cátedra de Lógica y Teoría de Grafos: desde el procesamiento de un conjunto de datos académicos empíricos hasta la implementación de una aplicación web interactiva con soporte a la toma de decisiones.

En el plano metodológico, se demostró la viabilidad de acoplar modelos predictivos estadísticos con algoritmos combinatorios discretos. La formulación diádica con partición por materias (*Node-Holdout Split*) permitió entrenar clasificadores capaces de generalizar a pares con materias inéditas sin incurrir en fuga de información marginal. Asimismo, el análisis de importancia de variables por reducción de impureza de Gini en el Árbol de Decisión oficial ratificó que la similitud histórica de co-inscripción (`jaccard_historico`, 38,59 %) y las matrículas de las materias constituyeron los predictores determinantes para anticipar la concurrencia estudiantil.

En cuanto a la selección del algoritmo de aprendizaje automático, la elección del Árbol de Decisión (`DecisionTree_Full_Unweighted`, $\tau = 0,20$) sobre KNN obedeció a un criterio de ingeniería operativa y no a una superioridad abstracta: aunque KNN alcanzó en prueba un recuerdo más alto (24,85 % frente a 15,46 %), lo hizo a costa de generar más del triple de falsos positivos (648 frente a 191 del árbol). En un problema de empaquetamiento temporal, la sobre-generación de falsos positivos densifica innecesariamente el grafo de restricciones y compromete la factibilidad del calendario.

Desde la perspectiva de la teoría de grafos, la heurística de coloreo voraz *Largest First* (Welsh-Powell) resolvió la asignación de las 800 materias en exactamente 11 turnos de examen sobre el grafo predicho ($|V| = 800, |E| = 2.032$), cumpliendo con holgura la cota institucional de 32 turnos. El análisis topológico de cotas cromáticas demostró que el cronograma opera muy cerca del número de clique maximal ($\omega(G) = 8$) y muy por debajo del grado máximo ($\Delta(G) = 38$). Asimismo, el barrido de umbrales evidenció la no-monotonicidad del coloreo voraz ante variaciones topológicas locales, ratificando la importancia del umbral τ como herramienta de exploración operativa.

Finalmente, la auditoría matemática frente a la cohorte histórica de 1994 aportó una lección pedagógica central: el sistema logra separar el 81,42 % de los pares en conflicto y reduce un 87,02 % las incidencias globales estudiante-par respecto del peor caso teórico, demostrando la eficacia del filtrado algorítmico. Sin embargo, debido a que cada alumno rinde en promedio 4,6 asignaturas, los 830 pares en conflicto no detectados por el modelo (falsos negativos) terminan alcanzando al 63,03 % de los estudiantes únicos. Este hallazgo ilustra que las herramientas de aprendizaje automático sobre datos agregados constituyen aproximaciones de gran valor preventivo para estructurar calendarios preliminares, pero deben complementarse necesariamente con instancias de optimización combinatoria y mecanismos institucionales de reasignación individual para las superposiciones residuales.